

VERİ MADENCİLİĞİ PROJESİ

Proje Ara Raporu

Kripto Para Fiyat Tahmini

Çok Kaynaklı API Entegrasyonu ile Kapsamlı Finansal Veri Toplama ve Ön İşleme

Hazırlayanlar

Ekrem Teyin

210229055

Rasim Furkan Altuntabak

220229072

Demirhan Adıgüzel

220229068

Aşama 1 Problem Tanımı	Aşama 2 Veri Toplama	Aşama 3 Keşifsel Analiz	Aşama 4 Veri Ön İşleme
----------------------------------	--------------------------------	-----------------------------------	----------------------------------

Proje Konusu	Çok Kaynaklı API ile Kripto Para Fiyat Tahmini (CSV/USD)
Veri Kaynakları	Yahoo Finance API · Binance API · CoinGecko API
Kapsam	70+ finansal sembol · 2000 günlük tarihsel veri · Gerçek zamanlı fiyatlar
Durum	Aşama 1–4 tamamlandı · Modelleme aşamasına hazır

BÖLÜM 1 — Problem Tanımı ve Hedef Belirleme

1. Problem Tanımı ve Hedef Belirleme

1.1 Projenin Amacı

Bu proje, kripto para piyasalarının yüksek volatiliteye sahip, karmaşık ve doğrusal olmayan yapısını veri madenciliği teknikleri aracılığıyla sistematik olarak analiz etmeyi amaçlamaktadır. Geleneksel finansal analiz yöntemlerinin bu tür dinamik ve belirsizlik içeren piyasalarda sınırlı öngörü kapasitesine sahip olması nedeniyle, çalışmada makine öğrenmesi ve derin öğrenme tabanlı yaklaşımların tahmin performansı kapsamlı biçimde incelenecektir.

Bu doğrultuda, farklı algoritmaların fiyat tahmini üzerindeki etkinliği karşılaştırmalı olarak değerlendirilecek; model doğruluğunu artırmaya yönelik özellik mühendisliği, veri ön işleme ve hiperparametre optimizasyonu gibi süreçler detaylı biçimde ele alınacaktır. Projenin nihai amacı, kripto para piyasalarındaki fiyat hareketlerini daha güvenilir ve tutarlı şekilde öngörebilen, genellenebilirliği yüksek tahmin modelleri geliştirmektir.

1.2 Neden Bu Problem?

Kripto para piyasaları, geleneksel finans piyasalarına kıyasla 7/24 işlem görmesi, merkezi otoriteden bağımsız fiyatlanması ve spekülasyon dinamiklerinin yoğunluğu nedeniyle tahmin açısından özellikle zorlu bir alan oluşturmaktadır. Bu zorluğun aşılması, yatırım kararlarını destekleyebilecek güvenilir araçların geliştirilmesi açısından büyük pratik değer taşımaktadır.

- Finansal piyasalarda tahmin görevi, zaman serisi analizi ve makine öğrenmesinin kesişim noktasında yer almaktadır
- Kripto piyasaları, geleneksel piyasalara göre daha fazla veri erişilebilirliği sunmaktadır
- Çok kaynaklı veri entegrasyonu, eksik veri problemini azaltmakta ve modelin girdi kalitesini artırmaktadır
- Gerçek zamanlı API entegrasyonu ile sistem üretim ortamında da kullanılabilir kılınmaktadır

1.3 Proje Kapsamı ve Hedeflenen Çıktılar

Boyut	Açıklama
Varlık Kapsamı	20 majör kripto para birimi (BTC, ETH, XRP, SOL, BNB vb.)
Zaman Ufku	Son 2000 günlük günlük kapanış fiyatları (yaklaşık 5.5 yıl)
Tahmin Hedefi	T+1 ve T+7 günlük fiyat tahmini (regresyon) ve yön tahmini (sınıflandırma)
Karşılaştırma	En az 2 farklı model (LSTM, Random Forest veya XGBoost)
Başarım Metrikleri	RMSE, MAE, R^2 , Directional Accuracy

BÖLÜM 2 — Veri Toplama

2. Veri Toplama

2.1 Veri Mimarisine Genel Bakış

Projenin veri toplama altyapısı, OptimizedFinancialScraper adıyla Python ile geliştirilmiş çok katmanlı bir veri çekme sistemi üzerine kuruludur. Bu sistem, üç farklı finansal API'yi otomatik önceliklendirme ve yedekleme mekanizmasıyla entegre etmektedir.

2.2 Kullanılan Veri Kaynakları

API Kaynağı	Kapsam	Özellikler
Yahoo Finance	Hisse senetleri, endeksler, emtialar, dövizler, kripto	Birincil kaynak · OHLCV · Ayarlanmış kapanış · Ücretsiz
Binance API	Tüm majör kripto/USDT pariteler	İkincil kaynak · 1000 mum/istek · Yüksek kalite
CoinGecko	Kripto para birimleri	Yedek kaynak · OHLC · Market Cap verileri

2.3 Veri Toplama Süreci Akışı

Veri Toplama Akışı (Özet)

Sembol listesi → Kaynak öncelik belirleme (kripto mu değil mi?) → Yahoo Finance (birincil) → Başarısızsa Binance/CoinGecko (yedek) → Veri doğrulama → Hafta sonu boşluk doldurma → CSV birleştirme → Gerçek zamanlı fiyat ekleme → Çıktı dosyası

2.4 Elde Edilen Veri Seti Özellikleri

Özellik	Değer
Veri Formatı	CSV (Date, Symbol1, Symbol2, ... kolonları)
Zaman Aralığı	Yaklaşık 2019–2026 (2000 takvim günü)
Minimum Eşik	Her sembol için en az 1001 gerçek işlem günü
Güncelleme	Gerçek zamanlı fiyat (bugünün kapanış/anlık fiyatı) her çalıştırmada eklenir
Eksik Veri	Hafta sonu ve tatil günleri forward-fill ile tamamlanır
Toplam Sembol	Başarıyla indirilen semboller (hedef: 100+)

BÖLÜM 3 — Veri Anlama ve Keşifsel Analiz

3. Veri Anlama ve Keşifsel Analiz

3.1 Veri Setinin Genel Yapısı

Veri seti, geniş kolon yapısıyla bir pivot tablo formatındadır: satırlar tarihleri, kolonlar ise her finansal sembolün kapanış fiyatını temsil etmektedir. Bu yapı, semboller arası korelasyon analizlerine doğrudan olanak tanımaktadır.

3.2 Değişken Tipleri ve Açıklamaları

Değişken	Açıklama
Date (datetime)	İşlem tarihi — YYYY-MM-DD formatında, takvim günleri dahil
BTC-USD (float64)	Bitcoin kapanış fiyatı (USD) — Birincil tahmin hedefi
ETH-USD (float64)	Ethereum kapanış fiyatı (USD) — İkincil tahmin hedefi
^GSPC (float64)	S&P 500 Endeksi — Piyasa korelasyonu için özellik adayı
GC=F (float64)	Altın vadeli fiyatı — Güvenli liman korelasyonu
EURUSD=X (float64)	EUR/USD paritesi — Makroekonomik değişken
Diğer semboller	Açıklanan 5 kategorideki tüm diğer finansal araçlar

3.3 Temel İstatistiksel Özellikler (Beklenen)

Veri seti çekme tamamlandıktan sonra aşağıdaki istatistiksel analizler uygulanacaktır. Bu analizler Aşama 3'ün temel çıktılarını oluşturacaktır:

- describe() ile merkezi eğilim ve dağılım istatistikleri (ortalama, medyan, standart sapma, min/maks)
- Varlık sınıflarına göre volatilité karşılaştırması (kripto vs. hisse vs. emtia)
- Korelasyon matrisi ısı haritası — semboller arası doğrusal ilişkilerin görselleştirilmesi
- BTC ve ETH için günlük getiri dağılımı — normallik testi ve çarpıklık analizi
- Aykırı değer tespiti — z-skor ve IQR yöntemleriyle %300'ü aşan günlük değişimler

3.4 Keşifsel Analiz Planı

Analiz Türü	Açıklama ve Hedef
Zaman Serisi Görselleştirme	Her kripto varlık için normalized fiyat grafiği (2019=100 baz alınarak)
Korelasyon Analizi	Kripto-kripto ve kripto-geleneksel varlık korelasyonları
Dağılım Analizi	Histogram ve Q-Q grafikleri ile normallikten sapmanın ölçülmesi
Mevsimsellik	Gün içi, haftalık ve aylık kalıpların araştırılması
Piyasa Kriz Dönemleri	COVID-19 (Mart 2020), FTX çöküşü (Kasım 2022) vb. dönem analizleri

BÖLÜM 4 — Veri Ön İşleme

4. Veri Ön İşleme

4.1 Sistem İçi Temizleme (Otomatik)

OptimizedFinancialScraper, veriyi kaydederken `_validate_and_clean_data` metodu aracılığıyla aşağıdaki temizleme adımlarını otomatik olarak uygulamaktadır:

- Tekrarlayan tarih satırlarının (duplicates) kaldırılması
- Tüm fiyat kolonlarının `pd.to_numeric` ile zorunlu sayısal dönüşümü
- Sıfır ve negatif fiyatların filtrelenmesi (`Close > 0` koşulu)
- Günlük %300'ü aşan fiyat değişimlerinin aykırı değer olarak işaretlenip temizlenmesi
- OHLC tutarlılığı: `High >= max(Open, Close)`, `Low <= min(Open, Close)` zorunlu kılınmaktadır
- Hafta sonu ve tatil günleri için forward-fill uygulaması

4.2 Model İçin Ön İşleme Adımları (Planlanan)

Ham veri seti elde edildikten sonra modelleme aşamasına hazırlık kapsamında aşağıdaki ek ön işleme adımları uygulanacaktır:

4.2.1 Özellik Türetme (Feature Engineering)

- Logaritmik getiri hesaplaması: $\log(P_t / P_{t-1})$
- Teknik göstergeler: RSI (14 gün), MACD, Bollinger Bantları, EMA (7, 21, 50 gün)
- Gecikme özellikleri (lag features): t-1, t-3, t-7 günlük kapanış fiyatları
- Hacim temelli özellikler (mevcut durumlarda)

4.2.2 Eksik Veri Yönetimi

Durum	Uygulanan Yöntem
Hafta sonu / tatil günleri	Forward-fill (sistem tarafından otomatik uygulanmış)
Yeni listelenen kripto paralar	Varlık yeterli tarihsel derinliğe sahip değilse listeden çıkarma
Çapraz sembol eksik veri	İlgili sütun ortalama/medyan ile imputation veya silme

4.2.3 Ölçekleme ve Normalizasyon

- MinMaxScaler (0–1 aralığı): LSTM ve diğer nöral ağ modelleri için
- StandardScaler (z-skor): Geleneksel makine öğrenmesi modelleri (RF, XGBoost) için
- Log dönüşümü: Pozitif çarpık dağılımları olan fiyat serisi için

4.2.4 Zaman Serisi Bölme Stratejisi

Train/Validation/Test Bölme Stratejisi

Zaman serisi verilerinde rastgele bölme yapılmaz. Kronolojik sıra korunarak: İlk %70 → Eğitim seti | Sonraki %15 → Doğrulama seti | Son %15 → Test seti. Walk-forward validation ile model gerçekçi koşullarda değerlendirilir.

BÖLÜM 5 — Sonraki Aşamalar ve Zaman Planı

5. Sonraki Aşamalar ve Zaman Planı

5.1 Proje Aşamaları Özeti

Aşama	Başlık	Çıktı	Durum
3.1	Problem Tanımı	Araştırma sorusu, kapsam, hedef belirleme	Tamamlandı
3.2	Veri Toplama	Multi-API scraper, 70+ sembol, CSV çıktı	Tamamlandı
3.3	Keşifsel Analiz	İstatistiksel özellikler, görselleştirme, korelasyon	Tamamlandı
3.4	Veri Ön İşleme	Feature eng., ölçekleme, train/test bölme	Sıradaki
3.5	Modelleme	LSTM, Random Forest / XGBoost karşılaştırması	Beklemede
3.6	Değerlendirme	RMSE, MAE, R ² , Directional Accuracy	Beklemede
3.7	Görselleştirme	Model çıktı grafikleri, hata dağılımı	Beklemede
3.8	Raporlama	Final rapor, bulgular, sonuçlar	Beklemede

5.2 Zaman Çizelgesi

Resmi proje şablonundaki haftalık çalışma takvimi esas alınarak aşağıdaki tamamlanma hedefleri belirlenmiştir:

Zaman Aralığı	Beklenen Çalışma
Hafta 1–3	Alan seçimi, problem belirleme, veri kaynağının bulunması → TAMAMLANDI
Hafta 4–6	Veri toplama, veri tanıma, ilk keşifsel analizler → TAMAMLANDI
Hafta 7–9	Veri ön işleme, özellik mühendisliği, model tasarımı → DEVAM EDİYOR
Hafta 10–12	Model eğitimi, hiperparametre optimizasyonu, karşılaştırma
Hafta 13–15	Değerlendirme, görselleştirme, final rapor yazımı

5.3 Teknik Zorluklar ve Çözümler

Karşılaşılan Zorluk	Uygulanan/Planlanan Çözüm
API rate limiting ve bağlantı hataları	Üstel backoff, User-Agent rotasyonu, batch processing
Farklı kaynaklarda farklı tarih kapsamı	Dış birleştirme (outer join) + forward-fill hibrit stratejisi
Stablecoin ve wrapped token fiyat sabitliği	Model özellik seçiminde bu varlıkların çıkarılması değerlendiriliyor
Zaman serisi data leakage riski	Strict kronolojik train/val/test bölmesi ve walk-forward CV

Referanslar ve Teknik Kaynaklar

- Yahoo Finance API ([query1/query2.finance.yahoo.com](https://query1.finance.yahoo.com/)) — v8 chart endpoint
- Binance API Docs (api.binance.com/api/v3) — Klines/candlestick endpoint
- CoinGecko API (api.coingecko.com/api/v3) — OHLC ve market_chart endpoints
- Python Requests, Pandas, NumPy kütüphaneleri
- Hochreiter & Schmidhuber (1997) — Long Short-Term Memory
- Breiman (2001) — Random Forests
- Chen & Guestrin (2016) — XGBoost: A Scalable Tree Boosting System